

WorkspaceX /chat 三维验收方案

普通用户验收手册 · Tools / Skills / 画布模板 · 路径覆盖 · 性能门禁

打印版 · Issue #2985

WorkspaceX 普通用户验收手册

本手册供不熟悉代码、数据库或自动化测试的业务用户使用。只需打开 WorkspaceX、按步骤操作并记录结果。开发和 QA 的技术矩阵见 [三维验收方案](#)。

1. 开始前

测试负责人应提供测试网址、版本 SHA、组织 A 和组织 B、组织 A 的管理员与普通成员账号、组织 B 普通成员账号、示例项目、组织知识库、只读示例数据库，以及以下合成附件：

- 中文 PDF、DOCX、XLSX、PPTX、PNG 和 CSV。
- 30 秒中英文音频、静音音频、损坏文件、密码保护 PDF。
- 所有文件必须是测试数据，不含真实客户资料、身份证件、密码或 API Key。

建议使用 Chrome。用普通窗口登录组织 A，用无痕窗口登录组织 B。每个场景开始前新建聊天，除非步骤明确要求沿用原线程。页面若要求普通用户输入系统密钥，立即停止并记为失败。

2. 记录方法

每个场景选择一个结论：

- 通过：实际结果与“应该看到”全部一致。
- 失败：结果错误、越权、数据丢失、重复执行、卡死或假成功。
- 受阻：环境缺数据、模型或服务，尚未执行到功能判断。

复制以下表格填写：

项目	记录
场景编号	UAT-
测试账号和组织	
开始和结束时间	
结果	通过 / 失败 / 受阻
实际看到	
截图或下载文件	
错误提示	
刷新后是否复现	

截图应包含地址栏、主要结果和错误提示。下载文件保留原名，不要修改后充当系统产物。

3. 用户验收场景

UAT-01 基础对话、连续对话和线程切换

1. 新建聊天，发送：“我正在准备一个面向大学生的阅读活动。请只回复三个活动目标。”
2. 回复结束后发送：“把刚才的第二个目标改写得更容易衡量，不要重复其他两个。”
3. 刷新浏览器。
4. 切换到另一个聊天，再切回来。

应该看到：第一轮持续出现回复；第二轮正确引用第一轮；刷新和切换后消息顺序、内容和状态不变；不会重复回复或永久停在运行中。

失败示例：忘记上一轮、刷新丢消息、切错线程、整页白屏。

覆盖：路径 P-A1/A2/A4/A5；WX-E001/E006、WX-T040。

UAT-02 计划、补参和人工确认

1. 发送：“帮我制定下周客户研究计划。”
2. 在补参卡片填写目标客户“新注册用户”、访谈人数“5”、完成时间“下周五”。
3. 如果出现方案选择，选择第二个方案。
4. 如果出现工具授权，先选择“拒绝”，确认没有文件或外部动作；重新开始后选择“仅本次允许”。
5. 刷新页面，确认仍是同一个待处理请求或完成结果。
6. 新建聊天发送：“1+1 等于多少？”

应该看到：复杂任务允许修改假设和参数；后续使用修改后的值；拒绝后无副作用；第二个方案只执行方案 B；简单问题直接回答。

失败示例：拒绝后仍执行、刷新生成新的审批、选择 B 却执行 A、简单问题强制复杂计划。

覆盖：P-B1 至 P-B7；WX-T009/T011/T012/T013。

UAT-03 附件、文件与隔离计算

1. 上传中文 TXT、PNG 和 CSV。
2. 发送：“列出我刚上传的文件，读取中文文本前五行，描述图片，计算 CSV 数值列总和，并把过程保存成 result.txt。”
3. 下载 result.txt，核对答案。
4. 发送：“把 result.txt 中的‘总和’替换为‘合计’，其他文字不要修改。”
5. 下载新版并比较。

应该看到：中文名完整；图片描述正确；总和与标准答案一致；第二版只改变目标词；文件可预览、下载并真实打开。

失败示例：访问未上传文件、乱码、修改无关内容、显示成功但文件为空或不能下载。

覆盖：WX-T001 至 WX-T008、WX-T018、WX-T020/T021。

UAT-04 联网研究

1. 发送：“搜索今天可公开访问的三个 AI 行业来源，比较它们对同一趋势的看法。每个结论附可打开链接，并指出分歧。”
2. 打开每个引用并核对。
3. 由负责人启用“搜索服务失败”开关，再重复请求。

应该看到：链接可打开且支持结论；分歧被保留；服务失败时明确说明无法核实，不生成假来源。

失败示例：链接无关、失败时仍声称已搜索、访问本机或内网地址。

覆盖：P-A3；WX-T014/T015、WX-S002。

UAT-05 组织知识和项目报告

1. 用组织 A 询问：“根据测试项目 Alpha 的资料，总结目标、进度和风险，每个关键结论附来源。”
2. 打开引用核对原文。
3. 让管理员撤销一篇测试资料的访问权限，再询问只存在于该资料中的事实。
4. 用组织 B 询问同一项目。

应该看到：回答与资料一致；未知字段明确标注；撤权后不再引用旧资料；组织 B 看不到名称、内容或项目是否存在。

覆盖：WX-T016/T017/T027/T028、WX-S001/S008/S014。

UAT-06 文档解析与理解

依次上传 PDF、DOCX、XLSX、扫描图片、损坏文件和密码 PDF，发送：“分别给出标题、页数或工作表、关键表格，并标出所在页码或位置。无法读取的文件单独说明原因。”

应该看到：内容和表格与原件一致；扫描页标注 OCR 和不确定内容；损坏或加密文件明确失败；撤销附件权限后不能从旧缓存继续回答。

覆盖：WX-T018/T019、WX-S018。

UAT-07 Word、Excel、PowerPoint 和 PDF

分别执行四个请求，每次都下载、关闭并重新打开产物：

1. Word：“生成两页中文 Word 报告，含标题、三段正文、三行表格和页眉。随后只修改第二段第一句。”
2. Excel：“生成销售和汇总两个工作表，汇总用公式求和。随后只改销售表第二行金额并重算。”
3. PowerPoint：“生成四页中文演示：封面、问题、方案、下一步。随后只改第三页标题。”
4. PDF：“生成三页 PDF，第二页含中文表格，第三页含可填写的验收人字段。”

应该看到：四类文件都能打开；中文不乱码、不裁切；页数或工作表正确；有限编辑只改变目标；Excel 公式正确；PDF 表单保存后重开仍有值。

失败示例：只验证文件大小、未知对象静默丢失、用覆盖矩形冒充安全脱敏。

覆盖：P-C6/C7；WX-T008/T019-T021、WX-S003 至 WX-S006。

UAT-08 画布和 19 个内置模板

1. 管理员打开画布模板库，逐个确认：用户画像、PESTEL、SWOT、同理心地图、待完成工作、用户旅程、价值主张画布、价值主张宣言、商业模式、MVP 实验、戏剧结构金字塔、汉堡沟通、三地横线、HMW、黄金圈、三视角、故事板、AI 战略、AI 商业模型。
2. 任选五个版式不同的模板预览。
3. 将“用户画像”绑定到测试项目，在 chat 中要求填入三张便签。
4. 放大，移动一张便签并保存；刷新后重开。
5. 在另一个窗口同时编辑同一便签。
6. 创建组织模板，完成试跑、发布、采用、归档、恢复。
7. 用组织 B 检查其不可见。

应该看到：19 个名称无重复；标题、分区、便签和连线不遮挡；保存后对象 ID 和分区正确；并发冲突不静默覆盖；归档不破坏既有实例；组织 B 不可见。

覆盖：P-C1 至 P-C4；WX-T029/T030、WX-S012、AT-C001 至 AT-C027。

UAT-09 网页产物与浏览器操作

1. 发送：“制作一个单页活动报名网页，包含姓名、邮箱、提交按钮和空状态，并适配手机。”
2. 打开预览，切换桌面和手机宽度。
3. 填写表单并提交。
4. 下载网页 bundle 并再次打开。

应该看到：按钮可用；手机无横向溢出；提交只发生一次；bundle 含真实 HTML。

失败示例：工具传输失败却显示完成、访问未授权内网、下载只有说明文字。

覆盖：WX-T022 至 WX-T026、WX-S013。

UAT-10 个人记忆

1. 发送：“请记住：我偏好中文回复，日期格式为 YYYY-MM-DD。”
2. 新建聊天询问日期偏好。
3. 发送：“忘记我的日期格式偏好。”
4. 再新建聊天询问。
5. 用第二个用户询问第一个用户的偏好。

应该看到：明确保存后跨会话生效；删除后不再使用；第二个用户看不到。

覆盖：WX-T031 至 WX-T033。

UAT-11 定时任务

1. 创建十分钟后执行的测试提醒。
2. 查看列表和下次执行时间。
3. 取消并重复取消。
4. 再创建两分钟后的任务并等待。

应该看到：时区正确；取消幂等且不会运行；未取消任务只产生一个 run；重启页面后仍可查。

覆盖：WX-E009、WX-T034 至 WX-T036。

UAT-12 音频、纪要和图片

1. 上传测试音频，要求转录并生成纪要。
2. 核对中英文片段、时间范围、决定和行动项。
3. 上传静音和损坏音频。
4. 发送：“生成一张 16:9 中文活动海报，标题‘阅读周’，蓝色背景。”

应该看到：纪要可定位原句或时间；未知说话人不被命名；静音和损坏文件明确处理；图片可打开且尺寸、文字正确。

覆盖：P-E1/E2；WX-T037/T038、WX-S009/S016/S017。

UAT-13 数据分析和图表

上传测试 CSV，发送：“分析各组平均值和缺失值，生成可重跑的计算脚本与柱状图。不要把相关性解释为因果。”

应该看到：数值与标准答案一致；缺失值策略写清；图表标签和颜色可辨；脚本重跑一致；缺失值没有被画成零。

覆盖：WX-S007/S020、WX-T008/T020。

UAT-14 访谈研究和内部沟通

1. 上传三份访谈，其中两份重复。
2. 要求综合主题、反对证据、引用和后续研究计划。
3. 要求生成内部沟通草稿，但不要发送。

应该看到：重复记录不重复计数；每个主题有来源；不推断缺失的人口属性；沟通稿保持草稿，无外发副作用。

覆盖：WX-S010/S011/S019。

UAT-15 创建和挂载 Skill

1. 发送：“创建个人 Skill 草稿：输入一组数字，输出数量和总和。包含 SKILL.md、示例和验证脚本。只保存草稿。”
2. 在 Skill 页面打开文件树，确认文件可读。
3. 试跑正确输入和非数字输入。
4. 临时挂载到当前聊天，刷新后再次使用。

应该看到：草稿未自动发布；正确输入准确；错误输入诚实失败；刷新后挂载一致；普通用户不能修改平台 Skill。

覆盖：P-D3/D4；WX-T039、WX-S015、WX-E004。

UAT-16 后台子任务、产物与取消

1. 发送：“后台生成三份独立文件：摘要.txt、数据.csv、说明.pdf。主任务继续显示状态。”
2. 关闭聊天页再返回。
3. 等待完成并下载三个文件。
4. 重复一次，但在运行中取消。

应该看到：返回后仍是同一批任务；三个文件回到父会话并可打开；取消后子任务停止，不出现晚到文件。

失败示例：只在内存显示完成、刷新消失、文件挂到错误子任务、取消后继续发布。

覆盖：P-C8/D6/F5；WX-T010/T020/T021/T040 至 WX-T042。

UAT-17 SQL 只读分析

1. 连接负责人提供的只读示例数据库。
2. 发送：“列出我可以访问的表，并说明 sales 表字段。”
3. 发送：“检查并执行查询：统计每个月销售总额。”
4. 发送：“把 sales 表所有金额改成 0。”
5. 用另一个账号重复列表。

应该看到：只列授权表；schema 和统计值正确；修改请求被拒；账号间范围隔离；页面和日志不显示连接密码。

覆盖：WX-T043 至 WX-T046。

UAT-18 断线、并发、失败与性能感受

1. 同时打开两个聊天，各发送一个约一分钟的任务。
2. 第一个任务运行时断网十秒，再恢复。
3. 对第二个任务依次暂停、恢复、取消。
4. 由负责人启用模型断流测试。

5. 记录每步开始、结束时间和是否卡死。

应该看到：两个 run 的消息、轨迹和文件不串线；重连后从原 run 续上；控制动作真实生效；断流后出现可理解终态，输入框仍可用。

普通用户只记录时间和感受，不计算 p50/p95。系统按性能标准分析原始样本。

覆盖：P-E4、P-F1 至 P-F7、PERF-07 至 PERF-10。

4. 最终签收

测试负责人汇总：

- 18 个 UAT 场景分别通过、失败或受阻多少项。
- 37 条路径是否仍有未覆盖或当前红。
- 46 Tools、20 Skills、9 个前置和 19 个模板是否都有正向与反向证据。
- 文件是否被真实打开，而非只看到下载卡片。
- 是否发生跨用户、跨组织或撤权后仍可访问。
- 性能样本是否由系统生成并绑定同一个版本 SHA。

只要出现越权、凭据泄露、假成功、取消后继续产生副作用、文件无法打开任一问题，该版本不能签收。

WorkspaceX /chat 三维验收方案：路径、能力与性能

跟踪：[Issue #2985](#)

适用基线：[docs/design/standard-capabilities/capability-catalog.json](#) (9 个平台前置、46 个 Tools、20 个 Skills)

目的：给开发、QA、独立 reviewer 和发布负责人提供同一份可执行完成契约。验收同时覆盖用户路径、Tools/Skills/画布模板能力、性能三个维度。

普通用户执行入口：[普通用户验收手册](#)。

1. 验收结论规则

本方案验证四个事实：能力已注册、真实运行链可达、结果可被终端用户使用、权限和失败链不会产生越权或假成功。测试文件存在、模型提到工具名、mock 返回成功、静态截图存在，都不能单独证明能力通过。

每项能力只有同时满足以下条件才能标记 **PASS**：

1. 对应正向行为通过，产出与用户可见出口一致。
2. 至少一个反向或越权场景按契约失败，且没有副作用。
3. trace 包含能力 ID、实际实现来源、run、actor、org、输入摘要、结果和耗时，不包含凭据。
4. 承诺文件产物时，必须重新打开并验证结构、MIME、字节 hash 和下载权限。
5. 需要真实模型或供应商的能力在 DevApp trusted lane 通过；loopback、fixture 和假模型只能记为组件通过。
6. 证据已上传到 CI artifact 或提交到允许的 evidence 目录，并绑定 exact SHA。

状态枚举：

状态	含义
PASS	所有适用层级和反证通过
PARTIAL	组件通过，但真实模型、DevApp、视觉或权限层尚缺
BLOCKED	实现或环境前置缺失
FAIL	已执行且行为不符合契约
N/A	经 reviewer 确认该层不适用，并写明理由

2. 测试层级与环境

层级	环境	验证内容	标准命令/入口
L0 契约	干净 checkout	ID、schema、依赖、别名、注册表一致	<code>pnpm run lint:skills-doctor</code> 、 <code>contracts Vitest</code>
L1 组件	隔离数据库/沙箱	领域规则、解析、序列化、风险等级	定向 Vitest、pytest
L2 服务集成	API + PostgreSQL + Deep Agent	真实 DI、HTTP、持久化、恢复、跨服务回调	<code>with-test-isolation.ts</code> 包装的定向测试
L3 浏览器 E2E	Web + API + DB	用户可见入口、HITL、下载、刷新恢复	Playwright fullstack lanes
L4 真实模型	DevApp trusted runner	模型选择、真实工具调用、真实文件、供应商错误	main-only manual workflows
L5 发布验收	DevApp 当前 main	部署、迁移、健康检查、回滚和审计	backend-gates deploy + devapp probe

共用夹具必须包含：组织 A/组织 B、同组织两个用户、可撤销成员关系、中文/英文文件、损坏文件、大结果、慢任务、并发 revision、可控 HTTP 站点、只读 SQL 数据集、19 个内置画布模板和一个组织自定义模板。

3. 三维覆盖模型

一条测试只有同时回答以下三个问题才算进入完整覆盖：

维度	要回答的问题	结果记录
P 路径	用户从哪个入口开始，经过哪些状态，看到什么结果，如何失败和恢复？	<code>pathId</code> 、现有 spec、覆盖状态
C 能力	路径真实调用了哪些 WX-E/WX-T/WX-S 和画布模板，权限是否逐层收窄？	<code>capabilityIds</code> 、tool trace、skill version、template key
R 性能	该路径的等待、流式、产物、并发或恢复是否符合性能事实源？	<code>slold</code> 、原始样本、p50/p95、机器负载

每条路径的最小证据键为：

```
{
  "pathId": "P-C8",
  "capabilityIds": ["WX-T010", "WX-T020", "WX-T021", "WX-T042"],
  "skillIds": [],
  "canvasTemplateKeys": [],
  "sloRefs": ["artifact-ready"],
  "exactSha": "<40-char sha>",
  "verdict": "PASS"
}
```

路径层 PASS 不能替代逐能力 PASS；同样，46 个 Tool 的组件测试全绿也不能证明用户能从 `/chat` 完成任务。性能只对已经功能正确的样本计时，错误结果再快也必须记为 FAIL。

4. /chat 路径全集与三维映射

覆盖状态来自仓库现有 spec 与当前验收输入。状态含义：已覆盖为存在真实行为 spec；部分/当前红为仅覆盖一层或现有 lane 未通过；未覆盖为没有对应端到端 spec。阈值只引用 [harness/instructions/chat-agent-performance-acceptance.md](#)，本表不复制数字。

Path ID	用户可见路径	当前覆盖 / spec	能力映射	性能映射
P-A1	单轮文本：一问一答入库并刷新恢复	已覆盖 · agent-chat-core-paths	E002/E006、T040	发送反馈、首字、流式连续
P-A2	多轮多线程：第二轮引用第一轮，run 独立持久化	已覆盖 · agent-chat-core-paths	E006、T040	缺第 N 轮首字
P-A3	长会话压缩后仍连贯且保留关键事实	未覆盖	E001/E006、S001/S002	缺上下文增长斜率
P-A4	线程切走再切回，无硬导航/骨架屏，历史正确	已覆盖 · copilotkit-v2-thread-persistence	E006、T040	缺线程切换耗时
P-A5	冷启动进入 /chat 到可输入	部分 · chat-route-warmup 仅预热	E001/E006	冷启动只记录，缺完整采样
P-B1	确认意图，可改假设并恢复同一 run	已覆盖 · agent-task-planning-hitl	T011、E006	HITL 出现/继续
P-B2	按 optionId 选方案；全部拒绝诚实结束	已覆盖 · agent-task-planning-hitl	T013、E006	HITL 出现/继续
P-B3	补参后同一 run 恢复，只显示一条轨迹/产物	已覆盖 · agent-task-clarification-result	T012、E006	HITL 出现/继续
P-B4	once/deny/forever 的真实服务端语义	已覆盖 · copilotkit-v2-hitl	E002/E006、受控 Tool	HITL 出现/继续
P-B5	刷新恢复同一 permissionRequestId	已覆盖 · copilotkit-v2-hitl	E006、T040	HITL 刷新恢复
P-B6	继续只提交一次，旧请求不可重复裁决	已覆盖 · agent-task-planning-hitl	E006、T011-T013	当前无独立 SLO
P-B7	复杂任务先确认，简单问题直接回答	当前红 · chat-task-workbench-workflow-states	T009/T011、Agent route	当前无独立 SLO
P-C1	canvas 围栏渲染为可用工作坊画布	已覆盖 · chat-canvas-guidance-render	T029/T030、S012、C001-C019	画布内嵌/放大
P-C2	最大化编辑→保存→reload→原始版	已覆盖 · chat-diagram-save-reopen-roundtrip	T029/T030、S012	画布刷新读回
P-C3	管理员建模板→发布→项目绑定→chat 可达	已覆盖 · core-journey-04	T029/T030、C020-C024	缺生命周期耗时
P-C4	同一轮生成两个模板且互不覆盖	未覆盖	T010/T029/T030、S012、C025	缺双产物耗时
P-C5	连续三轮各产一个产物，无闪烁/重复挂载	未覆盖	E006、T020/T021	缺第三轮产物耗时
P-C6	chat 请求 DOCX/XLSX/PPTX，可下载并重开	部分 · API 有 real stack，chat 无	T008/T020/T021、S003-S005	缺产物端到端耗时
P-C7	chat 请求 PDF，页数和逐页渲染正确	已覆盖 · real-model-pdf-smoke	T008/T019-T021、S006	缺产物端到端耗时
P-C8	durable subtask 文件回到父会话并下载	未覆盖	T010/T020/T021/T042	缺子任务产物耗时
P-D1	write_todos/search_documents 定制卡片到终态	已覆盖 · copilotkit-v2-tool-rendering	T009/T016/T017	工具事件呈现
P-D2	轨迹折叠、实时更新、刷新回放	已覆盖 · copilotkit-v2-tool-rendering	E006、T040	轨迹展开、100 条稳定
P-D3	会话挂载 Skill，刷新保留且幂等	已覆盖 · chat-agent-skill-context	E004、S001-S020	当前无独立 SLO
P-D4	发现元数据、读取正文、执行成功三态可区分	未覆盖	E004、S001-S020	当前无独立 SLO
P-D5	切换 Agent 后 header 与回复来源一致	已覆盖 · copilotkit-v2-agent-switch	E002/E004	当前无独立 SLO
P-D6	子 Agent 折叠树显示输入、工具、耗时、结果	当前红 · chat-task-workbench-tool-events	T010/T042	工具事件/轨迹展开
P-E1	麦克风转录进入输入框，可编辑并发送	已覆盖 · copilotkit-v2-voice-input	T037、S016	缺首段转录延迟
P-E2	图片进模型；能力缺席时诚实降级	已覆盖 · chat-vision-honest-degrade	T018/T038、S017	当前无独立 SLO

Path ID	用户可见路径	当前覆盖 / spec	能力映射	性能映射
P-E3	附件上传后可预览、下载且授权正确	已覆盖 · chat-attachment-preview-download	T018-T021	当前无独立 SLO
P-E4	运行中插话排队到安全步骤	已覆盖 · agent-workbench-steering-acceptance	E006、T040/T041	缺插话生效延迟
P-F1	真实失败显示可读横幅，界面仍可使用	已覆盖 · copilotkit-v2-error-banner	E006	当前无独立 SLO
P-F2	网络中断后 SSE/WS 重连并从 journal 续上	未覆盖	E006、T040	缺重连恢复时间
P-F3	暂停、恢复、取消、重试单步真实生效	当前红 · agent-workbench-control-acceptance	T040/T041	运行中刷新恢复
P-F4	失败步骤可重试或修改输入	当前红 · chat-task-workbench-workflow-states	E006、T040	当前无独立 SLO
P-F5	父取消传播，子任务无晚到产物	部分 · API 有，chat 无	T041/T042/T020	当前无独立 SLO
P-F6	两线程并发 run，事件不串线	未覆盖	E002/E006、T040/T042	缺并发劣化指标
P-F7	模型超时/断流后 UI 诚实结束	未覆盖	E006	缺失失败收敛时间

路径覆盖计数基线：22 条已覆盖、7 条部分覆盖或当前红、8 条未覆盖，共 37 条。机械门控落地后由脚本计算，文档中的数字仅作为首次导入基线。

5. 平台前置验收 (9 项)

测试 ID	能力	核心验收	必测反证
AT-E001	WX-E001 runtime-baseline	锁文件冷启动；导出真实依赖版本和工具 schema	缺依赖/配置显式失败；假模型探针不能标真实验收
AT-E002	WX-E002 capability-contracts	注册表与运行时 tool set 集合一致；旧别名唯一	伪造 org/user 无效；A/B 组织互不可见
AT-E003	WX-E003 sandbox-backend	write→execute→read→恢复真实闭环	穿越、技能包写入、禁网、超时、跨用户全部拒绝
AT-E004	WX-E004 skill-package-mount	SKILL.md、references、scripts、assets 渐进读取且脚本真实执行	缺文件、坏 hash、跨组织、版本切换不污染运行中快照
AT-E005	WX-E005 mcp-execution	discover→schema→call→observable side effect	未授权不触发 server；同名工具/凭据并发不串用
AT-E006	WX-E006 run-artifact-events	run、HITL、文件事件、恢复、取消状态一致	上传失败不显示 ready；重复 resume 不重复副作用
AT-E007	WX-E007 acceptance-runner	每项能力映射实际命令和 exact-SHA 证据	空测试集合、静态文件或 skipped lane 不能报告通过
AT-E008	WX-E008 migration-router	旧 ID 可发现；旧 run 可恢复；灰度切回	已产生对象和外部动作不重放
AT-E009	WX-E009 scheduled-run-adapter	重启后到期触发一次；时区/DST 策略确定	双 worker 不重复；取消后不再触发

6. Tools 验收矩阵 (46 项)

每行都必须执行正向、反向、trace 三类断言；“组合”列用于减少环境启动次数，不减少独立结果记录。

测试 ID	Tool	组合	关键正向断言	关键反证
AT-T001	WX-T001 <code>ls</code>	FS	中英文目录完整	不存在/无权路径不泄露
AT-T002	WX-T002 <code>read_file</code>	FS	分页行区间、图片内容块正确	越界路径拒绝
AT-T003	WX-T003 <code>write_file</code>	FS	UTF-8 写回 hash 相同	只读 skill 包不可写
AT-T004	WX-T004 <code>edit_file</code>	FS	只修改唯一目标片段	无匹配/歧义不写
AT-T005	WX-T005 <code>glob</code>	FS	嵌套及中文名匹配	不跨 workspace
AT-T006	WX-T006 <code>grep</code>	FS	命中、未命中、截断可区分	大结果不静默丢失
AT-T007	WX-T007 <code>delete</code>	FS	临时文件删除后不可见	附件原件、skill、其他 run 不可删
AT-T008	WX-T008 <code>execute</code>	FS	计算值和文件正确	非零、超时、取消、禁网可区分
AT-T009	WX-T009 <code>write_todos</code>	RUN	UI 状态投影且刷新保留	纯文字计划不算工具调用；坏 JSON 不编造状态
AT-T010	WX-T010 <code>task</code>	RUN	两个子任务独立返回	不继承未授权工具和其他租户文件
AT-T011	WX-T011 <code>confirm_task_intent</code>	HITL	用户修改假设后按新值继续	拒绝无副作用；他人不可代答
AT-T012	WX-T012 <code>fill_run_params</code>	HITL	编辑值经恢复传入执行	缺参不猜值；不声称未支持类型
AT-T013	WX-T013 <code>choose_execution_option</code>	HITL	选择 B 只执行 B	旧 ID、重复提交不二次执行
AT-T014	WX-T014 <code>web_search</code>	WEB	中英文实时结果含可打开来源	超时/配额不变空结果或编造
AT-T015	WX-T015 <code>fetch_url</code>	WEB	正文与 URL 可追溯且截断显式	localhost、metadata、危险重定向阻断
AT-T016	WX-T016 <code>wx_knowledge_search</code>	KNOW	授权资料及引用定位正确	撤回、跨租户、故障与零命中
AT-T017	WX-T017 <code>wx_knowledge_read</code>	KNOW	片段、页码/segment 与原文一致	搜索后撤回不可借旧 snapshot 读取
AT-T018	WX-T018 <code>wx_attachment_mount</code>	DOC	中文附件挂载后字节 hash 一致	伪造附件 ID、重复装载
AT-T019	WX-T019 <code>wx_document_parse</code>	DOC	PDF/Office/表格/OCR 有定位	密码、损坏文件、禁止出网
AT-T020	WX-T020 <code>wx_artifact_publish</code>	ART	UI、DB、对象存储 hash 一致	上传失败、无文件、MIME 错误不 ready
AT-T021	WX-T021 <code>wx_artifact_download</code>	ART	本人下载 hash 一致	第二用户、过期或重复兑换拒绝
AT-T022	WX-T022 <code>browser_navigate</code>	BROWSER	打开受控测试站	内网和跨 run context 拒绝
AT-T023	WX-T023 <code>browser_snapshot</code>	BROWSER	表单、按钮及结构正确	过期元素 ref 不误操作
AT-T024	WX-T024 <code>browser_click</code>	BROWSER	授权提交只产生一次动作	拒绝、旧 ref 无点击副作用
AT-T025	WX-T025 <code>browser_fill_form</code>	BROWSER	多字段填写值正确	错 ref 不写其他字段
AT-T026	WX-T026 <code>browser_take_screenshot</code>	BROWSER	图片可解码且裁剪正确	路径和图像不含其他 run 数据
AT-T027	WX-T027 <code>wx_project_list</code>	PROJECT	仅返回本人项目	无权项目不暴露名称/存在性
AT-T028	WX-T028 <code>wx_project_read</code>	PROJECT	多项目类型字段与 API 一致	撤回后拒绝；依赖失败不装空
AT-T029	WX-T029 <code>wx_canvas_read</code>	CANVAS	对象、关系、revision 往返不变	跨项目读取拒绝
AT-T030	WX-T030 <code>wx_canvas_update</code>	CANVAS	指定对象更新且 ID 不变	旧 revision 冲突；拒权零写入
AT-T031	WX-T031 <code>wx_memory_search</code>	MEMORY	跨会话读取明确保存的偏好	其他用户不可见；删除后不注入

测试 ID	Tool	组合	关键正向断言	关键反证
AT-T032	WX-T032 wx_memory_write	MEMORY	明确“记住”后跨会话生效且幂等	模型伪造 source、越权和冲突拒绝
AT-T033	WX-T033 wx_memory_delete	MEMORY	删除后新会话不使用	跨用户、旧 revision 拒绝
AT-T034	WX-T034 wx_schedule_create	SCHEDULE	到时进入同一 LangGraph 入口	无效时区、撤销后执行失败并通知
AT-T035	WX-T035 wx_schedule_list	SCHEDULE	nextRunAt 与本人任务正确	其他用户不可见
AT-T036	WX-T036 wx_schedule_cancel	SCHEDULE	取消后无新 run，重复取消幂等	运行中任务不谎称已停止
AT-T037	WX-T037 wx_audio_transcribe	MEDIA	中英文时间片段正确	无权、未知说话人、重复 transcript
AT-T038	WX-T038 wx_image_generate	MEDIA	图片可打开且记录模型/请求	无权参考图；不支持编辑时明确失败
AT-T039	WX-T039 wx_skill_create_draft	AUTHOR	多文件草稿版本和 hash 一致	穿越、缺依赖、普通用户写平台 skill 拒绝
AT-T040	WX-T040 wx_run_status	RUN	刷新后与后台一致并区分等待/执行	无权 run 不泄露步骤与文件
AT-T041	WX-T041 wx_run_cancel	RUN	长脚本及子任务最终取消且幂等	跨用户拒绝；完成/取消竞争终态确定
AT-T042	WX-T042 spawn_async_task	RUN	关闭主界面仍执行、可查询并返回真实产物	重试不重复；父取消不遗留沙箱
AT-T043	WX-T043 sql_db_list_tables	SQL	只列授权视图	连接/用户隔离；凭据不入模型/trace
AT-T044	WX-T044 sql_db_schema	SQL	字段和样例符合策略	无权表拒绝
AT-T045	WX-T045 sql_db_query_checker	SQL	错误查询给出可执行修正	checker 不执行查询或写入
AT-T046	WX-T046 sql_db_query	SQL	SELECT 结果与基准数据一致	UPDATE/DDL/越权视图拒绝；超时终止

7. Skills 验收矩阵 (20 项)

每个 Skill 使用两组最小样例：正向触发和相邻但不应触发的反例。含脚本或参考资料的包必须通过 trace 证明实际读取；Skill 提示词不能扩大 Tool 权限。

测试 ID	Skill	代表任务与可观察结果	必测反证
AT-S001	WX-S001 组织知识问答	有引用的组织事实回答	撤文后不引用；无结果明确未知
AT-S002	WX-S002 联网深度研究	多来源冲突报告和预算边界	搜索失败不编造来源
AT-S003	WX-S003 Word 创建/有限编辑	中英文多页、表格、页眉；目标段落编辑	无关段落 hash 不变；未知对象不静默丢失
AT-S004	WX-S004 表格创建/有限编辑	单元格、公式、重算和多 sheet	其他 sheet 不变；超限明确失败
AT-S005	WX-S005 演示创建/有限编辑	中文换行、字体、图片、逐页渲染	未知对象不静默丢失
AT-S006	WX-S006 PDF 处理	提取、页序、表单、渲染	覆盖矩形不得宣称安全脱敏
AT-S007	WX-S007 数据分析	已知答案数据集、缺失值记录、可重跑脚本	相关性不写成果
AT-S008	WX-S008 会议准备	目标、议程、参与者事实有来源	无资料时列缺口，不编造
AT-S009	WX-S009 会议纪要	决策/行动项定位原句或时间	建议不写成决定；责任人未知不猜
AT-S010	WX-S010 访谈综合	去重、主题、反对证据和来源	不推断缺失人口属性
AT-S011	WX-S011 组织沟通文稿	基于授权事实生成草稿	不外发；不编指标或泄露保密资料

测试 ID	Skill	代表任务与可观察结果	必测反证
AT-S012	WX-S012 图表与协作画布	对象身份往返、并发冲突	无权写入零副作用
AT-S013	WX-S013 交互网页产物	按钮、空状态、桌面/移动视口和可下载 bundle	未授权网络阻断；运输失败不伪装成功
AT-S014	WX-S014 项目进展报告	指标逐项映射 API 或标未知	未实现能力不写成可用
AT-S015	WX-S015 Skill 制作	多文件草稿可触发并验证依赖	草稿不等于发布；提示词不提权
AT-S016	WX-S016 音频转录	静音、损坏、时间范围和真实供应商样例	未提供身份不命名说话人
AT-S017	WX-S017 视觉内容	尺寸、文案、中文字体、来源和下载	错误不返回虚假产物
AT-S018	WX-S018 文档理解	跨页表格、扫描页、定位和结构	未识别不编造；撤权后缓存不可读
AT-S019	WX-S019 用户研究规划	问题映射目标，敏感题有必要性	不伪造受访者和发现
AT-S020	WX-S020 数据可视化	数字、标签、颜色、缺失值和静态导出	缺失值不当零；图表数值不可漂移

Office、PDF、网页、视觉和图表 Skill 的产物验收必须使用对应解析器重新打开；只检查文件大小大于零属于失败的验收设计。

8. 画布模板验收

8.1 内置模板身份

以下 19 个 key 必须与 [@repo/fabric-markdown](#) 注册表集合相等，且 displayName、字段 key、section、布局 and 版本均可读取：

测试 ID	key	显示名
AT-C001	persona	用户画像
AT-C002	pestel	PESTEL 分析
AT-C003	swot	SWOT 分析
AT-C004	empathy	同理心地图
AT-C005	jtbd	待完成工作画布
AT-C006	journey-map	用户旅程图
AT-C007	value-proposition	价值主张画布
AT-C008	adlib	价值主张宣言
AT-C009	bmc	商业模式画布
AT-C010	mvp	MVP 实验画布
AT-C011	freitag	戏剧结构金字塔
AT-C012	burger	汉堡沟通模型
AT-C013	three-horizons	三地平线模型

测试 ID	key	显示名
AT-C014	hmw	HMW 问题陈述
AT-C015	golden-circle	黄金圈法则
AT-C016	three-lenses	三视角模型
AT-C017	storyboard	故事板
AT-C018	ai-strategy	AI 战略画布
AT-C019	ai-bmc	AI 商业模型画布

每个模板执行统一场景：

1. 列表和详情可见，key 集合非空且无重复。
2. 创建实例后 section、field、token、对象 ID 和 binding key 正确。
3. Mermaid/Fabric 序列化往返保留支持对象和关系；坐标不会写回权威语义源。
4. 编辑 sticky 后 revision 单调递增；旧 revision 更新产生冲突。
5. 导出 PNG/PDF 可打开，边界、标题、便签、连接线不裁切。
6. 归档模板不影响既有实例；新项目不能继续采用已归档版本。

8.2 生命周期和权限场景

测试 ID	场景	通过标准
AT-C020	组织模板创建→编辑→试跑→发布→采用→归档→恢复	每次状态转换合法且审计可追溯
AT-C021	可见性	platform/org/private 三层结果与 actor 权限一致
AT-C022	版本固定	已采用实例不因模板新版本静默变化
AT-C023	三方合并	sticky、结构、布局按决策表处理；keep-both 可追踪
AT-C024	跨组织反证	B 组织无法发现、采用或修改 A 的模板
AT-C025	Agent 生成/套用	真实模型选择模板后，结构符合 schema，未知字段不写入
AT-C026	推荐	推荐理由与项目/阶段信号一致；无匹配时不强推
AT-C027	A1 布局视觉	12×8 网格边界内，无标题遮挡、连线压内容和不可读缩放

9. 性能维度

性能阈值、两层门控和采集契约的唯一事实源是 [.harness/instructions/chat-agent-performance-acceptance.md](#)。本方案只维护“哪条路径引用哪个 SLO”以及“哪些路径尚无 SLO”，不复制 p50、p95 或硬上限。

9.1 已有 SLO 的应用方式

- PR 硬门控使用固定 loopback、固定分片、单 worker，预热后重复采样。
- 定时基线保存至少事实源要求的有效样本；样本不足不得发布 p95。
- 浏览器用 performance.mark 与 MutationObserver 采 DOM 提交时间。
- 浏览器、journal 和服务日志通过 runId/attemptId/toolCallId/permissionRequestId 关联。
- 真实模型数据只进入趋势观测，不作为 PR 延迟硬门控。

9.2 缺失的性能覆盖

Perf ID	路径	需要加入现有 SLO 单源的指标	采样设计
PERF-01	P-A2/P-A3	第 N 轮首字和上下文增长斜率	固定任务采第 1/5/15 轮，比较趋势
PERF-02	P-A4	线程切换到历史可交互	热线程和含 100 条轨迹线程分别采样
PERF-03	P-C3	模板发布到项目 chat 可采用	分解 API 完成和 UI 可见两个时间点
PERF-04	P-C4/C5	双产物及第三轮产物 ready	单轮两个产物、连续三轮分别采
PERF-05	P-C6/C7/C8	DOCX/XLSX/PPTX/PDF/子任务产物 ready	发送→可下载，另记生成/上传/投影分段
PERF-06	P-E1	语音首段进入输入框	音频开始发送→第一段可编辑文本
PERF-07	P-E4	插话排队到生效	用户提交 steering→下一安全步骤消费
PERF-08	P-F2	断线重连恢复	断网→相同 run journal 和画面续上
PERF-09	P-F6	双 run 并发劣化	与单 run 基线比较首字和工具事件延迟
PERF-10	P-F7	上游失败收敛	供应商断流→UI 进入真实终态

这些指标必须通过修改现有 SLO 表的独立 PR落地；每行同时提供故障注入反证，证明采集器会变红。

10. 可执行测试套件

先运行静态和组件层：

```
pnpm install --frozen-lockfile
pnpm run lint:skills-doctor
pnpm --filter @repo/contracts test
pnpm --filter @repo/fabric-markdown exec vitest run
pnpm --filter @repo/fabric-markdown exec tsc --noEmit
pnpm --filter api exec vitest run tests/kernel tests/mcp tests/skill
pnpm --filter api exec vitest run tests/agent-runtime tests/agent-run
```

```
pnpm --filter api exec vitest run tests/canvas
pnpm --filter skill-sandbox test
```

需要数据库和完整应用的测试统一经过隔离包装：

```
pnpm exec tsx .harness/scripts/with-test-isolation.ts -- \
  pnpm --filter api exec vitest run \
  tests/skill/*real-db.test.ts \
  tests/agent-runtime/*real-db.test.ts
```

```
pnpm run verify:fullstack-smoke
pnpm run verify:core-loop
pnpm run verify:chat-task-workbench
node .harness/scripts/lint-spec-gate-coverage.mjs
```

真实模型和供应商能力只在 main、trusted self-hosted runner 执行。工作流必须绑定执行时的完整 main SHA，并对日志脱敏：

```
SHA=$(gh api repos/boardx/workspacex/commits/main --jq .sha)
gh workflow run real-model-chat-evidence --repo boardx/workspacex --ref main -f exact_sha="$SHA"
gh workflow run s013-real-model-evidence --repo boardx/workspacex --ref main -f exact_sha="$SHA"
gh workflow run s016-asr-real-evidence --repo boardx/workspacex --ref main -f exact_sha="$SHA"
```

在 Office、SQL、画布真实 lane 尚未成为 main 上的受信工作流前，对应项只能标 **PARTIAL** 或 **BLOCKED**。

11. 防假阳性与故障注入

每个组合套件至少做一次 mutation：

- 将预期 capability ID 改错，注册表测试必须失败。
- 将 org/user 换成另一个 fixture，读取或写入必须失败。
- 删除一个 Skill 包内引用文件，加载必须失败。
- 将 artifact MIME 与内容错配，发布必须失败。
- 把模板注册表替换成同样数量的假 key，集合测试必须失败。
- 中断数据库、对象存储、MCP、模型供应商和浏览器 transport，错误必须与零结果区分。
- 在上传成功前杀死 worker，恢复后不得重复外部副作用。
- 把全套测试过滤成零条，runner 必须因 collected/executed 数量为零而失败。


12. 证据清单

每次验收输出一个 manifest :

```
{
  "schemaVersion": 1,
  "capabilityId": "WX-T020",
  "testId": "AT-T020",
  "exactSha": "<40-char sha>",
  "environment": "ci|devapp",
  "actorFixture": "org-a-user-1",
  "commands": [<exact command>],
  "assertions": {"passed": 8, "failed": 0, "skipped": 0},
  "negativeProof": "<artifact-relative path>",
  "trace": "<artifact-relative path>",
  "artifacts": [{"path": "...", "sha256": "...", "mime": "..."}],
  "startedAt": "<ISO-8601>",
  "completedAt": "<ISO-8601>",
  "verdict": "PASS"
}
```

Manifest 不记录 token、cookie、数据库 URL、供应商 key 或完整敏感输入。CI artifact 保存原始输出；仓库文档只保存脱敏摘要和 artifact/run URL。

13. 并行执行与发布门禁



五个 B 组合可以并行；L4 真实模型 lane 按供应商限流并行，但共享 DevApp runner 时限制并发，避免资源竞争制造假失败。

发布门禁：

- 1. P0 前置、P0 Tools、P0 Skills 全部 PASS。
- 2. P1 项不存在未登记的 FAIL；允许延期的项必须有独立 issue、风险和 owner。
- 3. 19 个内置模板集合、组织模板生命周期、跨组织反证全部通过。
- 4. backend-gates、harness-verify、fullstack smoke 全绿。
- 5. DevApp 当前 main SHA 与 evidence SHA 相同，部署和数据库迁移成功。
- 6. 独立 reviewer 从 artifact 重放至少一个正向、一个越权反证和一个文件/画布产物。

14. 执行顺序与机械门控

- 1. 先清存量红线：chat-task-workbench 与 e2e-full 的现有失败先分诊；记录基线 run，不允许用新增 spec 掩盖。
- 2. 补九条零覆盖路径：优先 P-F2、P-C8、P-C5、P-F6，再做 P-C4、P-A3、P-F7、P-D4、P-A5。
- 3. 补性能映射：PERF-01 至 PERF-10 每项独立 issue/PR，在既有性能事实源加行并添加采样 spec。
- 4. 建立路径标签门控：E2E spec 使用 @path:P-C8 形式标注；脚本校验未知标签、重复权威、矩阵无 spec、spec 无路径四类漂移。
- 5. 做能力交集报告：每次 CI 从 trace 生成 Path×Capability 矩阵，任何 P0 WX 能力没有正向和反向证据即失败。
- 6. 真实模型对照：loopback 全绿后，以获授权的合成提示和合成文件运行关键路径；证据脱敏并绑定 main SHA。

B7、D6、F3、F4 涉及统一工作台控制面。实施测试前先读取 peer 已合入的契约符号，禁止另建并行状态机让测试“变绿”。

15. 当前已知缺口及拆分建议

以下是测试任务，不应塞进本方案文档 PR：

建议任务	优先级	内容
QA-01	P0	组织 Skill 晋升到平台的真库全链路
QA-02	P0	DOCX/XLSX/PPTX 创建、有限编辑、重开、视觉 QA 的 trusted lane
QA-03	P0	Deep Agent→API 子任务真实 HTTP、持久化和 artifact 回传
QA-04	P0	Tool 风险登记、真实注册、HITL 和执行路径一致性
QA-05	P1	组织画布模板完整生命周期浏览器 E2E
QA-06	P1	19 个模板批量结构、往返与视觉回归
QA-07	P1	真实模型驱动画布模板选择、生成和套用
QA-08	P1	SQL Toolkit 只读、RLS、超时、凭据脱敏
QA-09	P1	S013/S016/Office trusted runner 的凭据权限与失败清理

每个任务必须独立 issue、独立 PR，并在 PR 中列出覆盖的 **AT-*** 与 **WX-*** ID。父 Issue #2985 只在方案被 review 后关闭，不代表这些后续测试已经实现。